Calibrated Reliance on AI Writing Assistants: Effects of Confidence Cues on Accepting Suggestions

Jordan Lee and Sam Park

Sample paper written for the ko-paper README. All data are illustrative.

Abstract — People increasingly draft text with AI writing assistants, yet they often accept suggestions without checking them. We study whether showing a confidence cue next to each suggestion helps users rely on the assistant only when it is likely to be right. In a within-subjects study with 48 participants who edited short reports, confidence cues reduced the acceptance of incorrect suggestions by 31% while leaving the acceptance of correct ones almost unchanged. Participants also reported trust that tracked the assistant's actual accuracy more closely. We discuss how interface cues can support appropriate reliance rather than simply increasing trust.

1 Introduction

Writing assistants built on large language models now suggest whole sentences while people type. These suggestions save time, but they also invite overreliance: users accept fluent text even when it contains factual errors. Prior work on automation argues that the goal is not maximal trust but *calibrated* trust, in which a person's reliance matches the system's real capability.

We ask a simple question: does a visible confidence cue change which suggestions people accept? We contribute (1) a controlled study of confidence cues in a writing task, (2) a measure of calibration that combines acceptance and accuracy, and (3) design guidance for assistants that communicate uncertainty.

2 Method

Each participant edited twelve short reports. For every report the assistant offered four suggestions, one of which contained a planted error. In the *cue* condition, each suggestion carried a high, medium, or low confidence label; in the *baseline* condition, no label was shown. Condition order was counterbalanced.

We define the calibration score C of a participant as the difference between the acceptance rate of correct suggestions and the acceptance rate of incorrect ones:

$$C = P(\text{accept} \mid \text{correct}) - P(\text{accept} \mid \text{incorrect}) \tag{1}$$

A score of 1 means the participant accepted every correct suggestion and rejected every incorrect one; a score of 0 means acceptance did not depend on correctness.

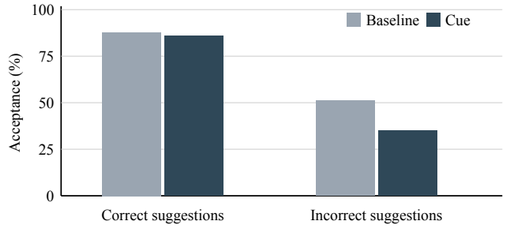


Figure 1: Acceptance rates by suggestion correctness. Confidence cues mainly lowered the acceptance of incorrect suggestions.

3 Results

Table 1 summarizes the main measures. With confidence cues, participants accepted far fewer incorrect suggestions, while acceptance of correct suggestions dropped only slightly. As a result, the mean calibration score rose from 0.37 to 0.51.

Table 1: Mean measures per condition (N = 48).

Measure	Baseline	Cue	Change
Accepted, correct (%)	87.8	85.9	−1.9
Accepted, incorrect (%)	51.0	35.2	−15.8
Calibration score C	0.37	0.51	+0.14
Task time (min)	6.4	6.9	+0.5
Self-reported trust (1–7)	5.6	5.1	−0.5

Editing took about half a minute longer with cues, which participants attributed to checking low-confidence suggestions more carefully. Self-reported trust decreased slightly, but it correlated more strongly with the assistant's accuracy on each report.

4 Discussion

Confidence cues did not make people trust the assistant more; they made people trust it more selectively. Designers should therefore evaluate assistants by calibration rather than

AI 글쓰기 어시스턴트에 대한 보정된 의존: 신뢰도 단서가 제안 수용에 미치는 영향

Jordan Lee and Sam Park

*ko-paper README*를 위해 작성한 예시 논문이다. 모든 데이터는 설명을 위한 가상의 값이다.

초록 — 사람들은 AI 글쓰기 어시스턴트로 글을 쓰는 일이 점점 늘고 있지만, 제안을 검증하지 않고 수용하는 경우가 많다. 본 연구는 각 제안 옆에 신뢰도 단서를 제시하면 어시스턴트가 옳을 가능성이 높을 때만 사용자가 이에 의존하도록 도울 수 있는지 살펴본다. 짧은 보고서를 편집한 참여자 48명을 대상으로 한 피험자 내 연구에서, 신뢰도 단서는 정확한 제안의 수용은 거의 바꾸지 않으면서 부정확한 제안의 수용을 31% 줄였다. 또한 참여자들은 어시스턴트의 실제 정확도를 더 가깝게 따르는 신뢰를 보고했다. 우리는 인터페이스 단서가 단순히 신뢰를 높이는 데 그치지 않고 적절한 의존을 어떻게 뒷받침할 수 있는지 논의한다.

1 서론

대규모 언어 모델 기반 글쓰기 어시스턴트는 이제 사용자가 입력하는 동안 문장 전체를 제안한다. 이러한 제안은 시간을 절약해 주지만 과의존을 부추기기도 한다. 사용자는 사실 오류가 있는 문장이라도 유창하면 수용한다. 자동화에 관한 선행 연구는 목표가 최대한의 신뢰가 아니라 보정된 신뢰, 즉 사람의 의존이 시스템의 실제 능력과 일치하는 상태라고 주장한다.

본 연구는 한 가지 단순한 질문을 던진다. 눈에 보이는 확신도 단서가 사람들이 수용하는 제안을 바꾸는가? 본 연구의 기여는 다음과 같다 . (1) 글쓰기 과제에서 확신도 단서를 통제하여 실험한 연구, (2) 수용과 정확도를 결합한 보정 측정 지표, (3) 불확실성을 전달하는 어시스턴트의 설계 지침이다.

2 방법

각 참여자는 짧은 보고서 열두 편을 편집했다. 어시스턴트는 보고서마다 제안 네 개를 제시했으며, 그중 하나에는 삽입된 오류가 있었다. 단서 조건에서는 각 제안에 높음, 중간, 낮음 중 하나의 확신도 라벨이 붙었고, 베이스라인 조건에서는 라벨을 표시하지 않았다. 조건 순서는 상쇄 균형화되었다.

참여자의 보정 점수 C를 정확한 제안의 수용률과 부정확한 제안의 수용률 간 차이로 정의한다.

$$C = P(\text{accept} \mid \text{correct}) - P(\text{accept} \mid \text{incorrect}) \tag{1}$$

점수가 1이면 참여자가 정확한 제안을 모두 수용하고 부정확한 제안을 모두 거부했다는 뜻이며, 0이면 수용 여부가 정확성에 좌우되지 않았다는 뜻이다.

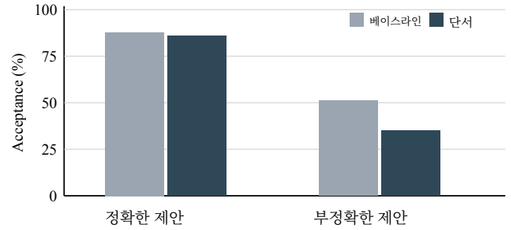


그림 1: 제안 정확성에 따른 수용률. 신뢰도 단서는 주로 부정확한 제안의 수용을 낮췄다.

3 결과

표 1은 주요 측정값을 요약한다. 신뢰도 단서를 제시하자 참여자는 부정확한 제안을 훨씬 적게 수용했고, 정확한 제안의 수용은 소폭 감소하는 데 그쳤다. 그 결과 평균 보정 점수는 0.37에서 0.51로 상승했다.

표 1: 조건별 평균 측정값 (N = 48).

측정 지표	베이스라인	단서	변화
수용됨, 정답 (%)	87.8	85.9	−1.9
수용됨, 오답 (%)	51.0	35.2	−15.8
보정 점수 C	0.37	0.51	+0.14
작업 시간 (분)	6.4	6.9	+0.5
자가 보고 신뢰 (1–7)	5.6	5.1	−0.5

신뢰도 표시를 제공하자 편집 시간이 약 30초 더 길어졌으며, 참여자들은 이를 낮은 신뢰도 제안을 더 꼼꼼히 확인했기 때문이라고 설명했다. 자가 보고 신뢰는 소폭 감소했으나, 각 보고서에 대한 어시스턴트의 정확도와는 더 강한 상관을 보였다.

4 논의

신뢰도 단서는 사람들이 어시스턴트를 더 많이 신뢰하게 만들지 않았으며, 오히려 더 선택적으로 신뢰하게 만들었다. 따라서 설계자는 어시스턴트를 평가할 때 수용만이 아니라 보정을 기준으로

by acceptance alone. A limitation is that our cues were perfectly informative; real confidence estimates are noisy, and poorly calibrated cues could mislead users.

References

[1] A. Author and B. Author. 2020. Appropriate reliance on automated advice. *Journal of Example Studies* 12, 3, 45–67.

[2] C. Author. 2022. Uncertainty displays in interactive systems. In *Proceedings of the Example Conference*, 101–110.

[3] D. Author and E. Author. 2024. Measuring overreliance on language model suggestions. arXiv:0000.00000.

삼아야 한다. 한 가지 한계는 본 연구의 단서가 완벽하게 정보를 제공했다는 점이다. 실제 신뢰도 추정치에는 잡음이 있으며, 보정이 미흡한 단서는 사용자를 오도할 수 있다.

References

[1] A. Author and B. Author. 2020. Appropriate reliance on automated advice. *Journal of Example Studies* 12, 3, 45–67.

[2] C. Author. 2022. Uncertainty displays in interactive systems. In *Proceedings of the Example Conference*, 101–110.

[3] D. Author and E. Author. 2024. Measuring overreliance on language model suggestions. arXiv:0000.00000.